Факультет компьютерных наук

Магистратура “Искусственный интеллект”

Москва 2026

Разработка кросс-доменной рекомендательной системы для e-com решения ресторанного бизнеса

Автор работы: Силиневич Илья Иосифович
Научный руководитель: Кантонистова Елена Олеговна

Цель работы

Цель работы - разработка **собственной системы рекомендаций для ресторанного e-commerce**, ориентированной на дополнение текущей корзины пользователя чтобы увеличить средний чек и выручку онлайн сервиса.

Для этого:
Используем **простые и интерпретируемые item-to-item модели** оптимизированные под комплементарность блюд, а не общую похожесть.

Задачи:

- Построить item-to-item рекомендательную систему для дополнения корзины
- Разработать методологию честной оценки (Debiased, OOT)
- Обучить и сравнить несколько классов моделей
- Выбрать production-ready модель с минимальной деградацией во времени

Предпосылки

Контекст и актуальность

- Рынок доставки готовой еды в России вырос с $2,3 млрд (2019) до $8+ млрд (2024) — рост в 3,5 раза за пять лет
- Онлайн-заказ стал основным каналом: ресторан видит сотни клиентов в день, но почти не знает их предпочтений
- Усилилась конкуренция. На рынок вышли новые игроки из ритейла

Проблема

- Пользователь видит 825+ позиций меню, но выбирает 3–7 блюд за один заказ
- Без рекомендаций большая часть ассортимента остаётся незамеченной
- Разница в точности рекомендаций на несколько п.п. прямо влияет на средний чек и конверсию

Постановка задачи

Формальная постановка

Дана корзина пользователя (набор уже выбранных товаров). Требуется предложить топ-5 товаров, которые пользователь с наибольшей вероятностью добавит к заказу.

Особенности предметной области

- **Большой каталог, малая сессия**. Пользователь видит сотни позиций, но выбирает 3–7 блюд за один заказ. Без рекомендаций большая часть ассортимента остаётся незамеченной.
- **Контекст корзины**. В отличие от других сфер электронной коммерции, ключевым сигналом является текущая корзина пользователя, а не его долгосрочная история заказов.
- **Высокая сезонность и дрейф**. Популярность блюд меняется с погодой, праздниками, временами года и сменой меню. Модели, обученные на данных прошлого года/сезона, могут деградировать на свежих данных.
- **Большинство сессий** - анонимные пользователи (проблема холодного старта)
- **Задача комплиментарности блюд** - а не общей похожести товаров

Выбранный подход - Item-to-item, модель принимает корзину и возвращает рекомендации, не используя профиль пользователя

Предметная область: рекомендательные системы

Подход	Принцип	Ограничения
Collaborative Filtering	Схожие пользователи покупают схожие товары	Cold start для новых пользователей
Content-Based	Схожесть атрибутов товаров	Слабо улавливает скрытые паттерны
Session-Based	Контекст текущей сессии/корзины	Требует достаточной длины сессии

Ключевые проблемы в рекомендациях:

- **Popularity bias**. Популярные товары доминируют в обучающей выборке, модели «льнут» к ним. Метрики завышаются за счёт предсказуемых хитов.
- **Temporal drift.** Предпочтения пользователей изменяются со временем. Оценка на свежих данных (Out-of-Time) критически важна для оценки реального качества.

Существующие решения

Решение	Open-Source	Готовый движок	Подходит для e-commerce/корзины
Gorse	+	Да	Да (нужно адаптировать)
Easyrec	+	Да	Да (более классические алгоритмы)
Implicit / LightFM	+	Частично (библиотеки)	Да (в составе кастомного решения)
RecBole	+	Нет (фреймворк)	Да (для исследований/экспериментов)
Retail Rocket	-	Да (SaaS)	Да (для e-commerce, но проприетарно)

Отличия проекта

От готовых open source решений

В отличие от универсальных open-source систем рекомендаций (таких как Gorse и easyRec), этот проект специально создан для задачи дополнения корзины блюд в онлайн-заказе в ресторане (horeca, ресторанный бизнес).
Используемые модели ориентированы на поиск подходящих дополнений к уже выбранным блюдам, поэтому их решения легко объяснять, контролировать и безопасно использовать на корзине и чек-ауте.
Архитектура проекта позволяет проводить воспроизводимые эксперименты и постепенно улучшать модели, сохраняя контроль над ключевыми бизнес-метриками.

В отличие от SaaS-решений вроде Retail Rocket, этот проект — не универсальный “чёрный ящик”, а простая и понятная система рекомендаций, специально созданная для ресторанной корзины и чек-аута.
Получаем полный контроль над логикой рекомендаций, легко объясняется бизнесу и безопаснее для ключевых этапов оформления заказа. Кроме того, решение полностью внутреннее, не требует внешних сервисов и проще адаптируется под реальные задачи ресторана.

Данные, временное разбиение

Датасет - история заказов пользователей в ресторане

Параметр	Значение
Пользователи	1,097 млн
Заказы	3,2 млн
Товары	825
Строки данных	22,223 млн

Структура данных:

- profile_id
- order_id
- item_id
- item_name
- quantity
- price
- date
- status

Разбивка по времени (Temporal Split)

|<-Train (365 дней)->|<-Test (30 дней)->|<-OOT (30дней)->|

- Train — основная обучающая выборка.
- Test — 30 дней непосредственно после обучающего периода; стандартная оценка.
- OOT (Out-of-Time) — последние 30 дней датасета (~47 дней после конца обучения); проверка устойчивости модели к временному дрейфу.

Схема Leave-One-Out

Из каждой корзины скрывается один случайный товар. Модель должна вернуть его в топ- рекомендаций. Схема исключает утечку данных и позволяет честно сравнивать модели.

Метрики качества

$$\text{Hit@K} = \frac{1}{|Q|}\sum_{q\in Q} \mathbf{1}\,[\text{target} \in \text{top-}K(q)] \qquad \text{MRR} = \frac{1}{|Q|}\sum_{q\in Q}\frac{1}{\text{rank}(\text{target}, q)}$$

- **Hit@K** — доля запросов, в которых скрытый товар попал в топ-.
- **MRR** — учитывает позицию правильного ответа

Debiased-оценка (борьба с popularity bias)

Стандартный Hit@5 переоценивает модели, хорошо предсказывающие «хиты» продаж.

Применяется **macro-усреднение по buckets популярности**:

1. Товары делятся на 5 квинтильных групп по частоте покупок.
2. Hit@5 считается отдельно по каждой группе.
3. Итоговый debiased Hit@5 = среднее по группам.

OOT Дрейф (temporal Stability)

Отрицательное значение указывает на деградацию модели при временном сдвиге.

$$\Delta_{\text{OOT}} = \frac{\text{Hit@5}_{\text{OOT}} - \text{Hit@5}_{\text{Test}}}{\text{Hit@5}_{\text{Test}}}$$

Архитектура системы

Система построена по принципу **двухуровневого ранжирования:**

- **Уровень 1 (Candidate Generation)** — базовые модели формируют множество кандидатов и числовые скоры.
- **Уровень 2 (Learning to Rank)** — LGBMEnsemble принимает скоры и признаки, ранжирует кандидатов.

Компонент	Назначение
orders.csv + products.csv	Сырые данные
DVC + Yandex S3	Версионирование данных и моделей
data.py	Формирование корзин, temporal split, LOO
Baseline-модели	Кандидаты и скоры первого уровня
SentenceTransformerBoost	Семантический ранжировщик
LGBMEnsemble	Финальный ранжировщик (LambdaRank)
CLI (python+ Hydra), Streamlit App	Интерфейс train / infer / app, Демо интерфейс сравнения

Архитектура production ready

Схема потоков данных (DFD)

- 1. Клиент (мобильное приложение) отправляет POST /recommend с корзиной
- 2. FastAPI вычисляет ключ кэша: MD5(sorted(item_ids))
- 3. Проверяет Redis: если ключ найден (cache hit) — возвращает сохранённый список рекомендаций
- 4. Если ключа нет (cache miss) — запускает LGBMEnsemble инференс
- 5. LGBMEnsemble использует скоры STBoost + CoocLift + item/basket features
- 6. Результат сохраняется в Redis и возвращается клиенту

Почему Redis

- Корзины часто повторяются (типовые наборы блюд)
- Инференс LGBMEnsemble ~7 мс, Redis hit < 1 мс — 7x ускорение на повторных запросах
- Горизонтально масштабируется при росте нагрузки

BaseLine модели

Модель	Принцип	Test Hit@5	OOT Δ
TopPopular	Глобальный рейтинг популярности	16,8%	−23,7%
CooccurrenceLift	NPMI/Lift совместных покупок	12,2%	−1,3% ✓
Item2Vec	Word2Vec на последовательностях корзин	7,1%	−37,4%
ImplicitALS	Matrix Factorization (ALS)	3,0%	—
ImplicitBPR	Bayesian Personalized Ranking	3,3%	−48,9%

SentenceTransformerBoost

Идея - использовать плотные многоязычные эмбеддинги для захвата семантической близости товаров — той информации, которую частотные модели не умеют извлекать.

Архитектура: 1. Каждый товар кодируется моделью intfloat/multilingual-e5-base (768 измерений) по конкатенации названия и описания. 2. Скор для пары «корзина — кандидат» вычисляется как взвешенная сумма:

$$\mathrm{score}(q,c) = \alpha \cdot \mathrm{cooc}(q,c) + \beta \cdot \mathrm{cat}(q,c) + \gamma \cdot \mathrm{sem}(q,c)$$

где:

- cooc — co-occurrence скор (NPMI),
- cat — бинарный признак совпадения категории,
- Sem— косинусное сходство эмбеддингов.
- Оптимальные веса:α=0,5 β=0,2 γ=0,3 (grid search по 27 комбинациям)

Результаты STBoost

Метрика	Значение
Test Hit@5	**17,62%**
OOT Δ	−3,1%

LGBMEnsemble: ранжировщик второго уровня

Принцип LGBMEnsemble — двухуровневый подход «stacking»: обученные модели первого уровня генерируют числовые скоры, которые вместе с пользовательскими и товарными признаками подаются на вход LightGBM-ранжировщика.

Обучение

- Алгоритм: **LambdaRank** (оптимизация NDCG).
- Целевая переменная: бинарная метка «скрытый товар» из LOO-схемы.
- Признаки (feature engineering):

Важность признаков (feature importance, gain)

1. score_STBoost — **1,9 млн** (доминирующий признак)
2. score_CoocLift — 0,8 млн
3. item_global_popularity — 0,4 млн
4. basket_category_diversity — 0,2 млн

Результаты LGBMEnsemble

Метрика	Значение
Test Hit@5	**25,96%**
Прирост vs TopPopular	**+55%**
OOT Δ	−0,6%

Эксперименты

Инфраструктура

Все эксперименты отслеживались в **MLflow**. Конфигурации управлялись через **Hydra** . Данные версионировались с помощью **DVC + Yandex S3**.

Ключевые эксперименты

1. **Ablation study для STBoost** grid search α, β, γ на 27 комбинациях → оптимум: α=0,5, β=0,2, γ=0,3
2. **Состав признаков LGBMEnsemble** полный набор, скоры + user + item + basket features — наилучший результат
3. **Вклад отдельных моделей** удаление STBoost снижает Hit@5 LGBMEnsemble на 4,3 п.п. — наибольший вклад
4. **Сравнение standard vs debiased оценки** разрыв −34,5% для TopPopular, только −12,1% для LGBMEnsemble
5. **Temporal stability** только CooccurrenceLift и LGBMEnsemble демонстрируют OOT-деградацию менее 5%.

Результаты

Модель	Test Hit@5	Test MRR	OOT Hit@5	OOT Δ
TopPopular	16,8%	0,1225	12,8%	−23,7%
CooccurrenceLift	12,2%	0,063	12,0%	**−1,3%**
Item2Vec	7,1%	0,038	4,5%	−37,4%
ImplicitALS	3,0%	0,016	—	—
ImplicitBPR	3,3%	0,017	1,7%	−48,9%
SentenceTransformerBoost	**17,6%**	**0,1214**	**17,1%**	**−3,1%**
LGBMEnsemble	**25,96%**	**0,1765**	**25,8%**	**−0,6%**

Ключевые выводы по результатам

- LGBMEnsemble достигает наивысшего качества по всем метрикам.
- Для реального продакшна пригодны только CoocLift и LGBMEnsemble (OOT деградация < 5%)
- Большинство популярных методов (ALS, BPR, Item2Vec) не работают для basket completion

Методология оценки

OOT- устойчивость по всем моделям

Модель	OOT Δ
ImplicitBPR	−48,9%
Item2Vec	−37,4%
TopPopular	−23,7%
STBoost	−3,1%
CooccurrenceLift	−1,3%
LGBMEnsemble	**−0,6%**

Debiased vs Standard Hit@5

Модель	Standard	Debiased	Разрыв
TopPopular	16,8%	11,0%	−34,5%
STBoost	17,6%	14,2%	−19,3%
LGBMEnsemble	25,96%	22,8%	**−12,1%**

Выводы:

- Стандартные метрики завышают качество моделей, смещённых к популярным товарам
- LGBMEnsemble наименее смещён: минимальный разрыв Standard vs Debiased

HIT@5 vs OOT деградация

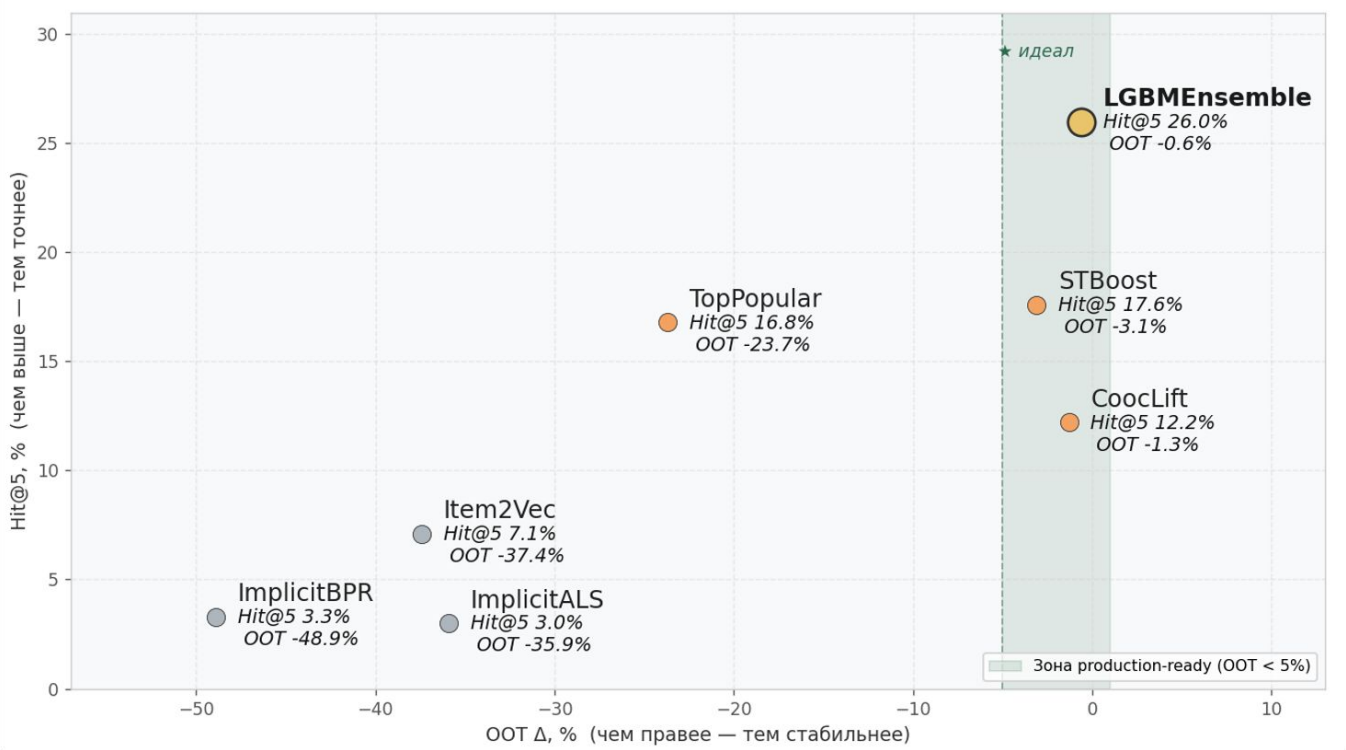

Выводы:

Точность на тестовой выборке — это ещё не всё.

TopPopular выглядел конкурентоспособно по Hit@5, но в реальных условиях он бы деградировал быстрее всех.

Выводы

1. **Разработан полный pipeline** item-to-item рекомендательной системы для ресторанного e-commerce — от сырых транзакций до работающего Streamlit-демо.
2. **LGBMEnsemble превосходит все baseline** по Test Hit@5 (25,96%), обеспечивая прирост +55% относительно TopPopular и деградацию OOT лишь −0,6%.
3. **STBoost доказывает ценность семантических эмбеддингов** для предметной области: улучшение Hit@5 и высокая OOT-устойчивость достигаются благодаря языковым представлениям товаров.
4. **Методология оценки важна не меньше модели.** Debiased-метрики раскрывают popularity bias (разрыв до −34,5%), а OOT-тест отделяет устойчивые модели от переобученных.
5. **Воспроизводимость обеспечена** сквозным использованием DVC, MLflow, Hydra, GitHub Actions CI.