Выпускная квалификационная работа на тему:

Разработка кросс-доменной рекомендательной системы для e-com решения ресторанного бизнеса

Студент
Силиневич Илья

Научный руководитель
Артем Носенко

Цель

Разработка собственной системы рекомендаций для ресторанного e-commerce, ориентированной на дополнение текущей корзины пользователя **чтобы увеличить средний чек и выручку онлайн сервиса.**

Для этого:

Используем **простые и интерпретируемые item-to-item модели** (co-occurrence с Lift, Item2Vec, popular baseline), оптимизированные под **комплементарность блюд**, а не общую похожесть.

Решение должно быть **легковесное, воспроизводимое и готовое к продакшену**, с фокусом на контроль качества, прозрачность логики и дальнейшее масштабирование.

Постановка ML задачи

Рекомендации для пользовательской корзины товаров

Вход:

текущая корзина пользователя [bucket, fries]

Выход: рекомендации

cola, sauce, nuggets

Существующие решения (краткий анализ)

Решение	Open-Source	Готовый рекомендательный движок	Подходит для e-commerce/корзины
Gorse	✅	Да	Да (нужно адаптировать)
easyrec	✅	Да	Да (более классические алгоритмы)
Implicit / LightFM	✅	Частично (библиотеки)	Да (в составе кастомного решения)
RecBole	✅	Нет (фреймворк)	Да (для исследований/экспериментов)
Retail Rocket	❌	Да (SaaS)	Да (для e-commerce, но проприетарно)

* составлено без учета международных SAAS сервисов

Отличия проекта от готовых open source решений

В отличие от универсальных open-source систем рекомендаций (таких как Gorse и easyRec), этот проект специально создан для задачи **дополнения корзины блюд** в онлайн-заказе в ресторане (horeca, ресторанный бизнес).

Используемые модели ориентированы на поиск **подходящих дополнений к уже выбранным блюдам**, поэтому их решения легко объяснять, контролировать и безопасно использовать на корзине и чек-ауте.

Архитектура проекта позволяет проводить воспроизводимые эксперименты и постепенно улучшать модели, сохраняя контроль над ключевыми бизнес-метриками.

Преимущества перед Saas решениями (на примере Retail Rocket)

В отличие от SaaS-решений вроде Retail Rocket, этот проект — не универсальный “чёрный ящик”, а простая и понятная система рекомендаций, специально созданная для ресторанной корзины и чек-аута.

Получаем полный контроль над логикой рекомендаций, легко объясняется бизнесу и безопаснее для ключевых этапов оформления заказа. Кроме того, решение полностью внутреннее, не требует внешних сервисов и проще адаптируется под реальные задачи ресторана.

Архитектура системы

```
+--------------------+
|  Orders Dataset    |
|  orders.csv        |
+---------+----------+
          |
          v
+--------------------+
|  Data Processing   |
|  data.py           |
|  - load csv        |
|  - filter orders   |
|  - build baskets   |
+---------+----------+
          |
          v
+--------------------+
|  Basket Dataset    |
|  [item1,item2...]  |
+---------+----------+
          |
          v
+--------------------+
|  Training Pipeline |
|  training.py       |
|  - train models    |
|  - evaluate        |
+---------+----------+
          |
+-----------------+------------------+
|                 |                  |
v                 v                  v
```

```
+--------------+  +-------------------+  +---------------+
| TopPopular   |  | CooccurrenceLift  |  |   Item2Vec    |
| baseline     |  | pair statistics   |  | embeddings    |
+------+-------+  +---------+---------+  +-------+-------+
       |                    |                    |
       +---------+----------+--------------------+
                 |
                 v
        +----------------------+
        | Evaluation           |
        | Hit@K / MRR          |
        +----------+----------+
                   |
                   v
        +----------------------+
        | MLflow Experiment    |
        | Tracking             |
        +----------+----------+
                   |
                   v
        +----------------------+
        | Inference            |
        | recommend(items)     |
        +----------+----------+
                   |
                   v
        +----------------------+
        | Recommended items    |
        | cola, nuggets ...    |
        +----------------------+
```

Данные, временное разбиение

Dataset - история заказов пользователей в ресторане

Параметр	**Значение**
Пользователи	8430
Заказы	9512
Товары	825
Строки данных	~39k

Структура данных:

- profile_id
- order_id
- item_id
- item_name
- quantity
- price
- date
- status

Каждый заказ → корзина товаров

Train / Test split

Train - старые заказы

Test - будущие заказы

Out-of-time evaluation

Янв | Фев | Мар

Train | Validation | Test

Модели, Lift, Item2Vec

Используемые модели

- TopPopular
- Cooccurrence Lift
- Item2Vec

$$Lift(i,j) = P(i,j) / (P(i)P(j))$$

Basket = sentence
Items = words

Baselines

- Implicit ALS
- LightFM

Метрики, результаты

Метрики

- Hit@K
- MRR

Cooccurrence Lift показывает лучший результат
для задачи basket completion.

Модель хорошо улавливает комплементарные
товары, которые часто покупаются вместе.

Model	Type	Hit@10	MRR
TopPopular	baseline	0.23	0.10
Cooccurrence Lift	item-to-item	**0.24**	**0.11**
Item2Vec	embedding	0.19	0.07
Implicit ALS	matrix factorization	0.22	0.09
LightFM	hybrid CF	0.22	0.09

Lift-based модель показывает лучшее качество при минимальной вычислительной сложности.

Преимущества проекта

1. Простота и эффективность моделей
Используются интерпретируемые и вычислительно лёгкие алгоритмы (Lift-based co-occurrence, Item2Vec), которые показывают конкурентное качество для задач basket completion в ресторанном домене.

2. Оптимизация под ресторанный сценарий
Модель ориентирована не на “похожие товары”, а на **комплементарные позиции**, что критично для увеличения среднего чека в доставке еды.

3. Полный контроль над решением
Отсутствие внешних SaaS-решений:

- нет лицензионных затрат,
- нет vendor lock,
- полный контроль над данными и логикой.

Преимущества проекта

4. Интерпретируемость и управляемость

Ассоциативные правила позволяют:

- объяснять рекомендации (“часто берут вместе”),
  быстро адаптироваться под акции, меню и бизнес-ограничения.

5. Production-ready архитектура

Использование DVC, MLflow, Hydra и CLI-интерфейса делает проект готовым к:

- экспериментам,
- масштабированию,
- последующему внедрению онлайн.

6. Четкий путь развития

Архитектура позволяет двигаться

- от basket-based рекомендаций к session-aware и causal uplift моделям без переписывания пайплайна.

Архитектура продакшн, Redis serving

Корзина

API

Redis кэш

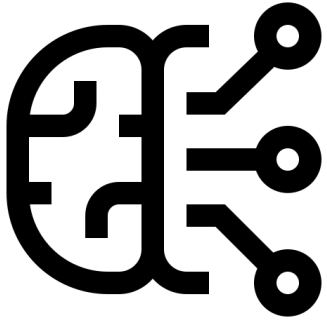

Тор рекомендаций

Дальнейший план проекта

09.03 – 12.03 Данные

- Загрузить расширенную выборку заказов (больше одного дня)
- Очистить данные (отмены, дубликаты)
- Обновить датасет через DVC.

12.03 – 15.03 Переобучение моделей

- Переобучить TopPopular, CooccurrenceLift, Item2Vec.
- Посчитать офлайн-метрики и сравнить с текущими.
- Зафиксировать лучшую модель для корзины.

15.03 – 18.03 Фиксация рекомендательного пайплайна

- Зафиксировать логику: вход (корзина), генерация кандидатов, фильтрация, top-K выдача.
- Обновить README / документацию.

18.03 – 22.03 Подготовка к использованию

- Определить формат API (вход / выход).
- Зафиксировать сценарии: корзина, чек-аут.
- Проверить стабильность инференса.

22.03 – 30.03 Финализация и выводы

- Финальная проверка на реальных корзинах.
- Краткие выводы: что работает, ограничения, идеи для следующего шага.

Выводы

- Разработана система рекомендаций
- Проведено сравнение нескольких моделей
- Подготовлена архитектура production

Метрики, результаты

Метрики

- Hit@K
- MRR

Cooccurrence Lift показывает лучший результат
для задачи basket completion.

Модель хорошо улавливает комплементарные
товары, которые часто покупаются вместе.

Модели	Hit@10	MRR
Popular	0.23	0.10
Lift	0.24	0.11
Item2Vec	0.19	0.07
ALS	0.22	0.09
LightFM	0.22	0.09

Lift-based модель показывает лучшее качество при минимальной вычислительной сложности.